


成果発表

2025/9/19

熊本大学大学院 自然科学教育部 M1

氏原 涼太

- 課題の趣旨
 - 人口とイベントの関係をモデル化
 - 将来のシナリオから人口を予測
 - 例) 2026年A市に工場ができた場合の人口の変化を予測



- 評価軸
 - **再現性**
 - データ, コード, 手順が明確で第三者が再現可能
 - **説明可能性**
 - イベント寄与の内訳を説明可能
 - **精度の妥当性**
 - 単純ベースラインに対して, 同等以上の安定性

・ダッシュボード（一部）

町丁と
イベント
を選択

シナリオ設定

基本設定

町丁

万楽寺町

イベント設定

イベントタイプ

住宅の減少・喪失

手動加算パラメータ


手動加算は0に固定されています（純粋なイベント効果を確認するため）

h1 (2026年) 手動加算

0.0

人口予測パス比較（イベントあり vs なし）

人口予測パス比較: 万楽寺町 (基準年: 2025)



- 熊本県熊本市
 - 町長単位で収集，モデル化
 - 1998年～2025年
- 選定理由
 - 地域に対する知識がある
 - 例1) A町にショッピングモールが建った
 - 例2) 何年に地震があった外国人が増えた
 - 知識に基づくモデル設計が可能

- 20??年の政令市化に伴う表記揺れ
 - 例 1) A町→A町 (東区)
 - 例 2) NULL→B町
 - 例 3) C町~~丁目→C町
- 表記揺れの統一
 - A町 (東区) , A町 (西区) はA町として扱う
 - B町は学習からは除外
 - C町~~丁目はC町として扱う
- **最終的に669町丁 X 28年 の人口データ**

- 異常値を検出
 - 自然減少以外の人口の変動を検知
 - 方法を説明
- イベントデータ
 - 年次, 町丁に基づく出来事
 - 約260件
 - 公的資料・公開情報を整理

イベント
マンション・アパート竣工
大型商業施設開業
学校・病院等新設
...

- モデル1：二方向固定効果モデル
 - 単純なイベントだけの効果を推定
 - 予測値(i, t) = 町丁 i らしさ + 年 t らしさ + イベントの効果

$$y_t^i = \alpha_i + \gamma_t + \beta$$

y_t^i : 予測値
 α_i : 地区 i らしさ
 γ_t : 年 t らしさ
 β : イベント効果

- 最小二乗法で α_i , γ_t , β を推定
 - $\alpha_i = -10$: 町丁 i は毎年-10人ずつ減っている
 - $\gamma_t = 20$: 年 t は全町丁で平均20人増えている
 - $\beta = 30$: あるイベントが起きると30人増える

- モデル2 : **LightGBM**
 - イベントを抜いた自然増減を捉え, 将来を予測
 - 勾配ブースティング決定木 (GBDT) の改良版
 - 勾配降下法 + アンサンブル学習 + 決定木
- 選定理由
 - 非線形・相互作用を拾える
 - 解釈しやすい
 - 学習・推論が高速



LightGBMの図

- 特徴量
 - 人口（前年度, 今年度）
 - イベント（マンション・アパート竣工など）
 - 時系列ラグ：イベントが何年後まで効果があるか
 - 外国人人口

- 目的変数
 - 人口増減率

$$r_t^i = \frac{\hat{y}_t^i - \hat{y}_{t-1}^i}{\hat{y}_{t-1}^i}$$

\hat{y}_t^i : t 町の i 年の人口
 r_t^i : t 町の i 年の人口増減率

- 将来予測の算出方法

$$y_t^i = \hat{y}_{t-1}^i (1 + r_t^i)$$

y_t^i : t 町の i 年の人口予測値

- 人口の大きさを考慮した予測が可能
 - 例) 1000人から1100人 と 100人から200人は訳が違う

- 学習方式

- 時系列クロスバリデーション

- 学習期間が一年ずつ伸びていく
 - (ステップ 1) 1999年-2017年→2018年を予測
 - (ステップ 2) 1999年-2018年→2019年を予測

- 損失関数

- Huber損失

- 外れ値にロバスト

$$L_{\delta}(y) = \begin{cases} \frac{1}{2} (y - \hat{y})^2 & (|y - \hat{y}| \leq \delta) \\ \delta \left(|y - \hat{y}| - \frac{\delta}{2} \right) & (|y - \hat{y}| > \delta) \end{cases}$$

- 評価指標
 - 強みが異なる4つの指標で総合的に評価

評価指標	値範囲	目安	意味
MAE	0～無限	小さいほど良い	誤差の絶対値の平均
$RMSE$	0～無限	小さいほど良い	誤差の二乗の平均の平方根
$MAPE$	0～無限	小さいほど良い	実際の値に対して何%ずれているか
R^2	-無限～1	大きいほど良い	1 : 予測と実測値が同じ 0 : 平均値で予測したのと同じ 負 : 平均値予測より悪い

- 比較対象（ベースライン）
 - ランダムウォーク（ドリフトなし）
 - 最低ライン比較対象

$$N_t^i = \hat{N}_{t-1}^i$$

- 移動平均
 - ファ

$$N_t^i = \frac{1}{k} \sum_{j=1}^k \hat{N}_{t-j}^i$$

- 精度
 - ベースラインに対して全ての指標で高い性能

モデル	MAE ↓	$RMSE$ ↓	$MAPE$ ↓	R^2 ↑
ランダムウォーク	21.88	44.67	2.55	-1.01
移動平均	19.01	37.71	1.90	-0.30
LightGBM	<u>2.62</u>	<u>11.08</u>	<u>0.70</u>	<u>0.87</u>

- 将来予測のデモを紹介
 - 図

- **構造変化年の外れ**（住居表示変更・再開発・災害直後）への補正が未実装
- **将来イベントデータの運用設計**（更新頻度・責任部署・入力様式）
- **評価設計の強化**（W-MAPEの徹底、人口ビン別%誤差の可視化）

- 課題
 - 人口とイベントの関係をモデル化
- 目的

二方向効果モデル

19/15

- 最小二乗法

- 残差二乗和 (RSS) を最小にする係数を求める

$$RSS(\alpha, \gamma, \beta) = \sum_{i,t} \left(\hat{y}_{i,t} - (\alpha_i A_i + \gamma_t D_t + \beta E_{i,t}) \right)^2$$

$\hat{y}_{i,t}$: 実測値
 α_i : 町丁 i らしさ
 A_i : 町丁の0/1
 γ_t : 年 t らしさ
 D_t : 年の0/1
 β : イベント効果
 $E_{i,t}$: イベントの0/1

- 残差 $u = Y - X\theta$

$$X = \begin{bmatrix} A_1 & D_1 & E_{1,1} \\ A_1 & D_2 & E_{1,2} \\ \vdots & \vdots & \vdots \\ A_n & D_2 & E_{n,2} \end{bmatrix}$$

$$\theta = \begin{bmatrix} \alpha \\ \gamma \\ \beta \end{bmatrix}$$

二方向効果モデル

20/15

- 残差二乗和 (RSS) を最小化 = 微分が 0

$$RSS(\theta) = (Y - X\theta)'(Y - X\theta)$$

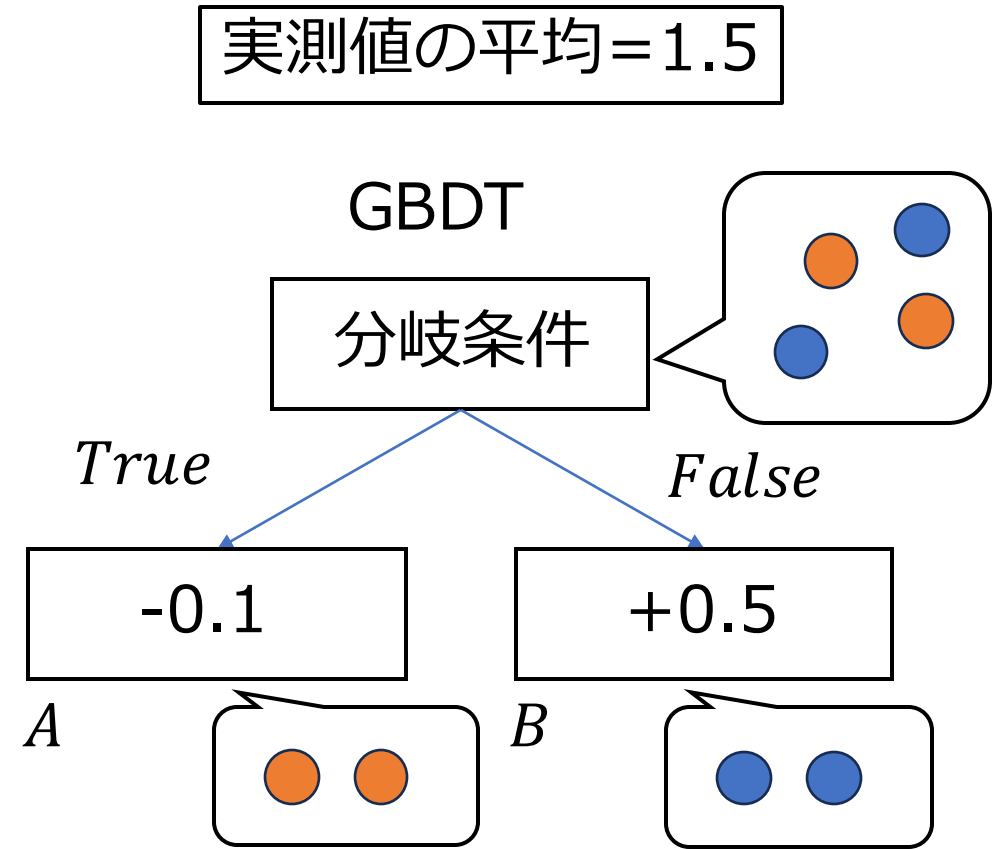
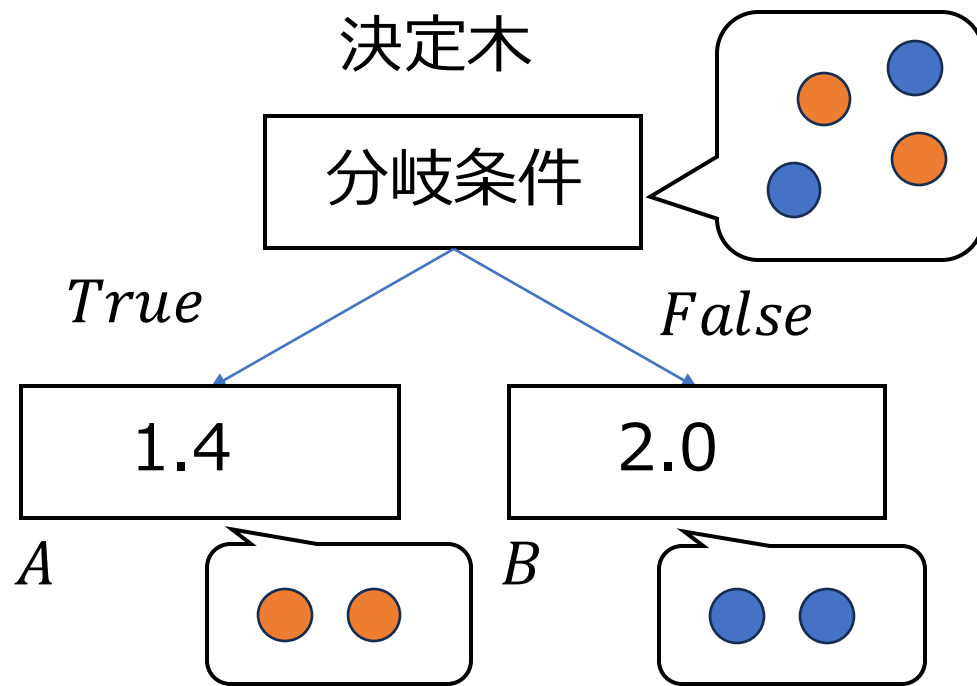
$$\begin{aligned}\frac{dRSS(\theta)}{d\theta} &= (Y - X\theta)'(Y - X\theta) \\ &= -2X'Y + 2X'X\theta = 0\end{aligned}$$

- $\theta = (X'X)^{-1}X'Y$ を解くと, イベント効果 β を推定可能

勾配ブースティング決定木 (GBDT)

21/15

- 決定木：葉ノード=出力値
- GBDT：葉ノード=残差



勾配ブースティング決定木 (GBDT)

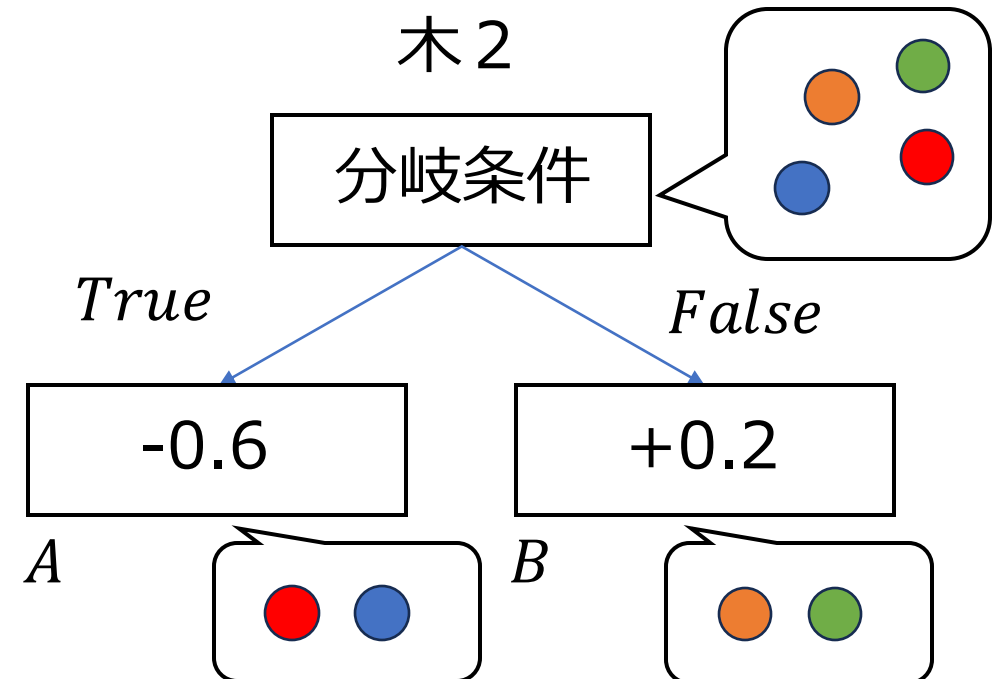
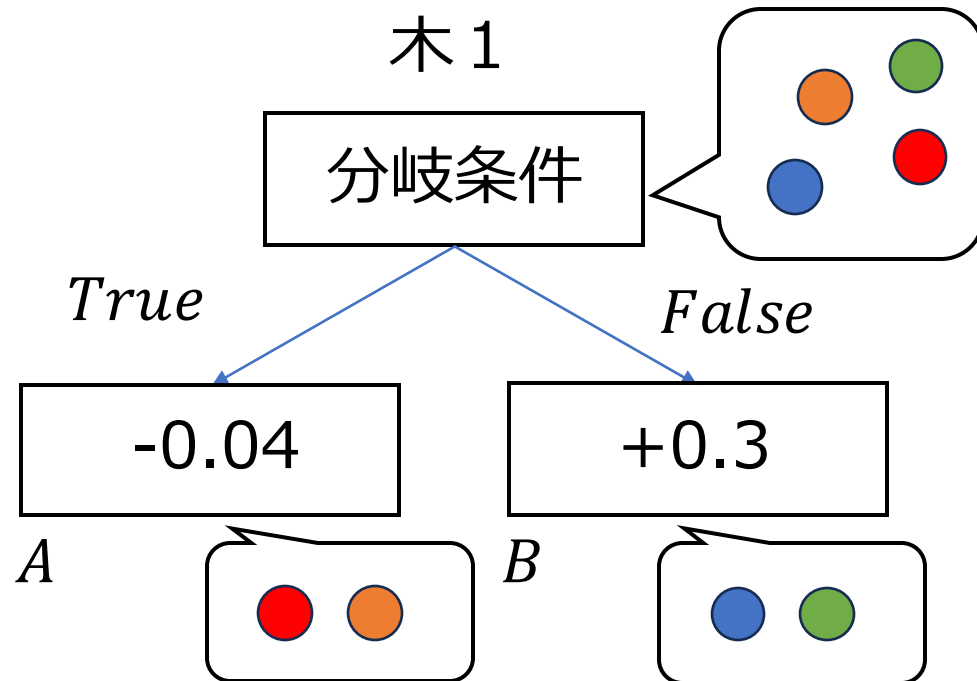
22/15

- GBDT : 決定木 + アンサンブル学習 + 勾配降下法

- の実測値 = 1.6

- の計算式 = $1.5 - 0.04 - 0.6 = 1.4$

実測値の平均 = 1.5



勾配ブースティング決定木 (GBDT)

24/15

- 分岐の決定法

- 分岐：

$$x_{i,j} < t_j$$

- 特徴量分繰り返す

1. 閾値 t_j を変動
2. 損失 L を計算

例)平均二乗誤差

$$L = \frac{1}{n} \sum_{i=1}^n (y_{i,j} - \bar{y}_j)^2$$

- L が最も小さい（特徴量,閾値）のペア = 分岐

勾配ブースティング決定木 (GBDT)

25/15

- 葉の出力

- 出力 : $c=1.703$

- 全データの平均値 F_0 を計算

- 分岐終了

- 残差 r を計算

- r に学習率 γ をかけて, F_0 に足す

$$r_k = \frac{1}{\text{count}(Leaf_k)} \sum_{i \in Leaf_k} y_i - F_0$$

$$F_1(x) = F_0 + \gamma r_{k \in Leaf_k}$$

- 2本目以降

- 新しい決定木に従って出力

$$F_n(x) = F_{n-1} + \gamma r_{k \in Leaf_k}$$

- Huber損失

- 閾値 δ が大きいほど外れ値に強い
- 重い外れのあるデータにロバスト
 - 政令市化による町丁区域の変更などに対応

$$L_{\delta}(y) = \begin{cases} \frac{1}{2} (y - \hat{y})^2 & (|y - \hat{y}| \leq \delta) \\ \delta \left(|y - \hat{y}| - \frac{\delta}{2} \right) & (|y - \hat{y}| > \delta) \end{cases}$$

y : 予測値

\hat{y} : 実測値

δ : 閾値 (0~1)

- MAE (Mean Absolute Error : 平均絶対誤差)

- 計算式

$$MAE = \frac{1}{n} \sum_{i=1}^n |y_i - \hat{y}_i|$$

- 範囲 : 0~無限 / 小さいほど良い
 - 強み : ハズレ値に引っ張られにくい
 - 弱み : 大外しを強く罰しない

- RMSE (Root Mean Squared Error : 二乗平均平方根誤差)

- 計算式

$$RMSE = \sqrt{\frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2}$$

- 範囲 : 0~無限 / 小さいほど良い
 - 強み : 大外しに敏感
 - 弱み : 少しの外れ値で数字が大きくなりやすい

- MAPE (Mean Absolute Percentage Error : 平均絶対パーセント誤差)

- 計算式

$$MAPE = \frac{100}{n} \sum_{i=1}^n \left| \frac{y_i - \hat{y}_i}{y_i} \right|$$

- 範囲 : 0%~無限% / 小さいほど良い
- 強み : スケールに依存しない
- 弱み : y が小さいと爆発

- R^2 (決定係数)

- 計算式

$$R^2 = 1 - \frac{\sum_{i=1}^n (y_i - \hat{y}_i)^2}{\sum_{i=1}^n (y_i - \bar{y}_i)^2}$$

- 範囲：-無限~1 / 大きいほど良い
 - 強み：モデルが分散をどれだけ説明したかを表す
 - 弱み：集計の仕方で値がぶれる

- アブレーション
 - 外国人～～

モデル	MAE ↓	RMSE ↓	MAPE ↓	R ² ↑
フルモデル	21.88	44.67	2.55	-1.01
移動平均	19.01	37.71	1.90	-0.30
LightGBM	<u>2.62</u>	<u>11.08</u>	<u>0.70</u>	<u>0.87</u>